



Projet Intégratif ITIneraire

Arrigoni Ambroise, Fougeray Paul, Sanson Dylan, Sourdrille Nathan,
Zouaghi Rayen

ITI3 groupe 1



Titre :

Projet Intégratif ITIneraire

Matières :

Capteurs et Statistiques

Période du projet :

Mars-Mai 2025

Groupe de projet :

Groupe 9

Participant(s) :

Arrigoni Ambroise

Fougeray Paul

Sanson Dylan

Sourdrille Nathan

Zouaghi Rayan

Superviseur(s) :

Condat Robin

Rogozan Alexandrina

Nombre de pages : 38

Date de réalisation :

28 mai 2025

Résumé:

L'objectif de ce projet d'intégration est de concurrencer l'application mobile Strava, dédiée pour l'enregistrement des activités sportives par GPS. Pour cela, vous devrez concevoir et développer un système d'acquisition permettant l'estimation de trajectoire d'un parcours fait à pied.

Table des matières

1	Introduction	2
2	Présentation des capteurs à notre disposition	3
2.1	Description et fonctionnement	3
2.1.1	GPS	3
2.1.2	Accéléromètre	3
2.1.3	Gyroscope	4
2.1.4	Magnétomètre	4
2.1.5	LiDAR	4
2.2	Avantages et inconvénients	6
2.3	Sources de bruitages et/ou défauts techniques	8
2.4	Calibration effectuée	9
2.4.1	Démarche	9
2.4.2	Expérimentations	9
2.5	Choix des paramètres d'acquisition	11
2.5.1	Test d'homogénéité des variances	11
2.5.2	Sélection empirique du meilleur paramétrage	11
2.6	Filtrage des signaux bruts	12
2.6.1	Synchronisation des signaux	12
2.6.2	Détection des valeurs aberrantes	12
2.6.3	Lissage et filtrage complémentaire	12
2.6.4	Résultat du prétraitement	12
3	Présentation du système d'acquisition complet	13
3.1	Montage électrique	13
3.2	Description du produit (fonctionnalités, mode d'utilisation)	14
3.3	Synchronisation des capteurs	14
3.4	Fusion de données détaillée	14
4	Analyse des performances du système d'acquisition	15
4.1	Méthodologie pour la détermination du paramétrage du système d'acquisition	15
4.2	Description et analyse du choix des méthodes statistiques avec les résultats obtenus	15
4.3	Analyse des résultats de tracking obtenus	19
4.3.1	Mouvement extérieur 1	19
4.4	Analyse des résultats obtenus en cas de défaillance capteur	23
4.4.1	Acquisition immobile extérieur 1	23
4.4.2	Acquisition immobile extérieur 2	26
4.5	Filtrage des signaux bruts	29
	Bibliographie	38

Chapitre 1

Introduction

L'objectif principal de ce projet est de concevoir un capteur de position destiné à une application de type STRAVA, dédiée au suivi et à l'analyse des activités sportives en extérieur. Ce dispositif sera constitué de plusieurs capteurs intégrés, notamment un GPS, un accéléromètre, un gyroscope et un magnétomètre. L'intégration de ces différents capteurs vise à fournir des données précises et fiables sur la position, le mouvement et l'orientation de l'utilisateur.

Ce projet s'inscrit dans le cadre de notre formation et constitue une mise en pratique concrète des connaissances théoriques acquises en cours, notamment en matière de capteurs. Il offre également l'opportunité d'appliquer des outils mathématiques, en particulier des méthodes statistiques avancées. À ce titre, l'un des axes majeurs de notre travail sera l'utilisation du filtre de Kalman, un algorithme de filtrage permettant de fusionner efficacement les données issues de capteurs multiples, tout en tenant compte de leur incertitude respective.

Au-delà des aspects techniques, ce projet mettra en valeur le travail en équipe, la répartition des tâches, la collaboration entre membres et la capacité à mener un projet technique de bout en bout. Il s'agit donc d'un exercice complet, à la fois technique, méthodologique et collaboratif, nous préparant à des projets similaires dans un cadre professionnel.

Chapitre 2

Présentation des capteurs à notre disposition

Cette partie a pour but de présenter les capteurs que nous avons utilisés lors des travaux pratiques.

2.1 Description et fonctionnement

2.1.1 GPS

Le capteur GPS (Global Positioning System) est un composant permettant de capter les signaux envoyés par les satellites GPS afin de déterminer une position géographique précise. Pour rappel, le GPS est le nom du système GNSS (Global Navigation Satellite System) développé par les États-Unis. Il s'agit d'un système de positionnement basé sur des satellites artificiels placés en orbite et fonctionnant de manière coordonnée.

Ce réseau repose sur une constellation d'environ 30 satellites opérationnels, situés à une altitude d'environ 20 200 km. La précision pour les usages civils varie généralement entre 3 et 5 mètres. Plus le nombre de satellites captés est élevé, plus la précision augmente, notamment grâce à la correction des erreurs liées à l'atmosphère ou aux interférences.

Il fournit typiquement des données de latitude, longitude, altitude, vitesse et temps. Ce capteur est essentiel pour le suivi de trajectoire.

2.1.2 Accéléromètre

Un accéléromètre est un dispositif qui mesure l'accélération (ou le mouvement) auquel il est soumis en appliquant le principe fondamentale de la dynamique :

$$\vec{F} = m\vec{a}.$$

En termes simples, l'accéléromètre détecte les changements de vitesse ou de direction. L'accéléromètre fonctionne en mesurant la force exercée sur un petit composant interne, souvent une masse suspendue à un ressort ou un capteur piézoélectrique. Cette masse se déplace en fonction des variations d'accélération de l'objet. Plus l'objet accélère, plus cette masse se déplace. Ce mouvement est ensuite mesuré par le capteur.

L'accéléromètre mesure les accélérations linéaires le long des trois axes (X, Y et Z). Il permet ainsi de détecter les mouvements, les chocs, et d'estimer l'orientation d'un objet (comme l'inclinaison).

2.1.3 Gyroscope

Le gyroscope est un capteur qui mesure la vitesse angulaire, c'est-à-dire la rapidité avec laquelle un objet tourne autour de ses axes (X, Y ou Z). Contrairement à l'accéléromètre qui détecte des mouvements linéaires, le gyroscope mesure les rotations. Le principe de fonctionnement du gyroscope repose sur la conservation du moment cinétique. Lorsqu'un rotor (ou masse tournante) est mis en rotation, il tend à conserver son orientation dans l'espace, conformément à la loi :

$$\frac{d\vec{L}_O}{dt} = 0 \Rightarrow \vec{L}_O = \vec{C}t$$

avec \vec{L}_O le moment cinétique par rapport à un point O.

Dans les gyroscopes MEMS (Micro-Electro-Mechanical Systems) modernes, cette rotation est généralement mesurée par effet Coriolis. Une petite structure oscillante à l'intérieur du capteur subit une déviation lorsqu'elle est en mouvement de rotation. Cette déviation est proportionnelle à la vitesse angulaire et peut être détectée électriquement.

Grâce à ces mesures, le gyroscope est capable de suivre les changements d'orientation d'un appareil, ce qui le rend essentiel pour notre processus de développement.

2.1.4 Magnétomètre

Le magnétomètre est un capteur qui mesure l'intensité et la direction d'un champ magnétique, généralement celui de la Terre. Il fonctionne comme une boussole numérique, permettant de déterminer l'orientation absolue d'un objet par rapport au nord magnétique. Contrairement au gyroscope, qui mesure des vitesses de rotation relatives, le magnétomètre fournit un repère fixe dans l'espace.

Le principe de fonctionnement le plus courant repose sur l'effet Hall. Lorsqu'un courant électrique traverse un conducteur ou un semi-conducteur soumis à un champ magnétique perpendiculaire, une différence de potentiel apparaît sur les côtés du matériau. Cette tension, appelée tension de Hall, est proportionnelle à l'intensité du champ magnétique traversant le capteur. Elle est mesurée électroniquement pour en déduire la composante du champ magnétique selon chaque axe (X, Y, Z).

Pour cette raison, il est souvent combiné avec un gyroscope et un accéléromètre, permettant une estimation plus fiable et précise de l'orientation dans l'espace.

2.1.5 LiDAR

Le LiDAR (Light Detection and Ranging) est un capteur qui mesure la distance entre un capteur et un objet en utilisant des impulsions lumineuses, généralement des lasers. Il permet de cartographier avec précision l'environnement en trois dimensions en mesurant le temps mis par la lumière pour revenir après avoir été réfléchi par un objet.

Le principe de fonctionnement repose sur la mesure du temps de vol (Time of Flight) d'un faisceau laser. Le capteur émet une impulsion lumineuse, puis détecte le retour de celle-ci après réflexion. En connaissant la vitesse de la lumière, il est possible de calculer la distance

avec une grande précision. Cette méthode permet d'obtenir un nuage de points représentant la géométrie de l'environnement.

Grâce à sa capacité à fournir des mesures précises, même dans des conditions de faible luminosité, le LiDAR est largement utilisé en robotique, en cartographie et dans les véhicules autonomes pour la détection d'obstacles et la navigation.

2.2 Avantages et inconvénients

Chaque capteur mesure une grandeur physique, mais aucun capteur n'est parfait. Chacun présente des atouts et des limitations qu'il convient de connaître afin de concevoir un système de mesure fiable.

- **GPS :**

- *Avantages :*

Le GPS a une bonne précision géographique (de l'ordre de quelques mètres pour un GPS civil).

De plus, il fonctionne de manière autonome. En effet, il n'a pas besoin d'infrastructure locale. En outre, il permet de déterminer la position absolue sur le globe (latitude, longitude, altitude).

- *Limites :*

Même si le GPS nous offre plusieurs avantages. Ce dernier a quelques limites à ne pas ignorer. En fait, il a une latence élevée de l'ordre de plusieurs centaines de millisecondes à quelques secondes.

Le GPS a aussi une faible fréquence d'échantillonnage (entre 1Hz et 10Hz), ce qui n'est parfois pas suffisant surtout pour capter les dynamiques rapides. Il ne faut pas oublier aussi qu'il est peu fiable en environnements clos comme les bâtiments, tunnels, etc... car il nécessite une ligne de vue avec les satellites. Finalement, le GPS est vulnérable aux interférences radio et au brouillage.

- **Accéléromètre**

- *Avantages :*

L'accéléromètre nous offre une mesure directe de l'accélération linéaire dans les 3 axes (x,y,z). En effet, ce dernier est très utile pour détecter les chocs, les mouvements ou les vibrations. Sa haute fréquence d'échantillonnage (plusieurs KHz) lui permet d'avoir un suivi précis des changements rapides. Les avantages les plus importants de l'accéléromètre sont sa taille et son coût. En effet, il est peu coûteux et très compact.

- *Limites :*

Tout comme le GPS, l'accéléromètre a ses inconvénients. En fait, un accéléromètre est très sensible au bruit (bruit thermique, vibrations parasites). Les mesures nécessitent souvent un filtrage notamment : un filtre passe-bas ou filtre de Kalman. De plus, un accéléromètre ne donne pas la position absolue. Il donne seulement des informations relatives au mouvement.

- **Gyroscope :**

- *Avantages :*

Le gyroscope permet de mesurer la vitesse angulaire, c'est-à-dire les rotations autour des axes.

Il est très réactif et précis à court terme, ce qui le rend particulièrement utile pour détecter des changements rapides d'orientation.

Grâce à sa haute fréquence d'échantillonnage, il est capable de suivre les mouvements avec une grande précision en temps réel.

– *Limites :*

Cependant, le gyroscope présente aussi certaines limites.

Il souffre notamment d'un phénomène appelé *dérive* : les petites erreurs de mesure s'accumulent avec le temps, ce qui dégrade la précision à long terme si le capteur n'est pas recalibré.

De plus, il consomme généralement plus d'énergie que d'autres capteurs comme l'accéléromètre, ce qui peut poser problème dans les systèmes autonomes.

• **Magnétomètre :**

– *Avantages :*

Le magnétomètre mesure le champ magnétique terrestre, ce qui permet d'estimer l'orientation absolue par rapport au nord magnétique.

Contrairement au gyroscope, il ne dérive pas avec le temps.

Il est donc particulièrement utile pour corriger les erreurs d'orientation dans les systèmes de navigation.

– *Limites :*

Le principal inconvénient du magnétomètre est sa grande sensibilité aux perturbations magnétiques locales.

En présence de métaux ferromagnétiques ou de champs électromagnétiques générés par des appareils électroniques, ses mesures peuvent devenir très imprécises.

Il nécessite souvent un étalonnage régulier pour fonctionner correctement, notamment en environnement intérieur ou urbain dense.

• **LiDAR :**

– *Avantages :*

Le LiDAR permet de mesurer avec une grande précision la distance aux objets en utilisant des impulsions lumineuses.

Il génère un nuage de points 3D détaillé, utile pour la cartographie, la détection d'obstacles et la modélisation de l'environnement.

Contrairement aux caméras, il fonctionne efficacement dans des conditions de faible luminosité ou d'obscurité totale.

– *Limites :*

Le LiDAR peut être sensible aux conditions atmosphériques (pluie, brouillard, poussière) qui affectent la propagation des impulsions lumineuses.

Il peut également être coûteux, énergivore, et sa portée est limitée par la puissance du faisceau et les propriétés réfléchissantes des surfaces.

Les surfaces transparentes ou très absorbantes peuvent entraîner des erreurs ou des absences de mesure.

2.3 Sources de bruitages et/ou défauts techniques

Les capteurs sont sujets à différents types de bruits :

Sources de bruit des capteurs :

- **GPS** : Bien que largement utilisé, le GPS reste sensible à divers bruits et erreurs. Les conditions atmosphériques, comme les variations dans la troposphère et l'ionosphère, peuvent déformer les signaux satellites, entraînant des erreurs de position. En zone urbaine ou montagneuse, les obstacles bloquent les signaux ou limitent la visibilité des satellites, réduisant la précision. De plus, le phénomène de multipath, où les signaux rebondissent avant d'atteindre le récepteur, fausse le calcul des distances.
- **Accéléromètre et gyroscope** : Les capteurs inertiels souffrent d'erreurs internes dues à leur structure physique et électronique. Le *bruit thermique*, causé par l'agitation des électrons, génère des fluctuations aléatoires. Les *biais*, erreurs constantes influencées par la température ou l'usure, s'accumulent lors de l'intégration des mesures, entraînant une *dérive* : le système détecte un mouvement inexistant. S'y ajoutent les erreurs d'alignement et les vibrations mécaniques, rendant ces capteurs peu fiables seuls sur le long terme sans recalibrage ou fusion de données.
- **Magnétomètre** : Ce capteur mesure le champ magnétique terrestre, utile pour estimer l'orientation absolue (nord-sud). Cependant, sa fiabilité dépend fortement de l'environnement. Les objets *ferromagnétiques* et les sources *électromagnétiques* (moteurs, câbles, etc.) peuvent perturber la mesure. En intérieur, ces interférences sont fréquentes. Un *étalonnage* régulier, par mouvements circulaires, est nécessaire pour corriger ces erreurs. Malgré cela, le magnétomètre reste peu fiable seul pour l'orientation.
- **LiDAR** :

Le LiDAR mesure la distance aux objets en envoyant des impulsions laser et en analysant leur temps de vol. Il fournit une représentation 3D précise de l'environnement. Cependant, plusieurs sources de bruit ou défauts techniques peuvent affecter la qualité des mesures.

Les conditions atmosphériques telles que le brouillard, la pluie ou la poussière dispersent ou absorbent partiellement le faisceau laser, réduisant la portée effective et la précision du retour. Les surfaces très réfléchissantes (comme le verre ou les miroirs) peuvent provoquer des réflexions multiples, entraînant des mesures erronées ou décalées. À l'inverse, les matériaux sombres ou absorbants (comme les tissus noirs ou certaines peintures mates) peuvent réfléchir très peu de lumière, générant des données incomplètes ou du bruit.

Des erreurs peuvent aussi survenir à cause de la géométrie de la scène : des angles trop inclinés par rapport au capteur réduisent la puissance du signal réfléchi. De plus, les vibrations du support ou des erreurs de synchronisation dans les systèmes multi-capteurs peuvent introduire du flou ou des artefacts dans le nuage de points. Enfin, les LiDARs à balayage mécanique peuvent s'user ou se désaligner avec le temps, affectant leur précision.

Malgré ces limitations, le LiDAR reste l'un des capteurs les plus fiables pour la perception 3D, notamment lorsqu'il est utilisé en complément d'autres capteurs.

2.4 Calibration effectuée

2.4.1 Démarche

La calibration vise à réduire les erreurs systématiques. Cette section concerne uniquement le gyroscope. En effet, ce capteur présente une dérive dans le temps, même en l'absence de mouvement. Cela est principalement dû à un biais constant propre à chaque axe de mesure. Il est donc nécessaire d'estimer ce biais afin de le soustraire dynamiquement aux données lors de l'utilisation.

2.4.2 Expérimentations

Pour ce faire, nous avons réalisé une acquisition en maintenant le système complètement à l'arrêt. En théorie, les vitesses angulaires mesurées devraient être nulles. Cependant, on observe que les valeurs dérivent légèrement dans le temps, indiquant la présence d'un biais.

Nous avons enregistré les mesures sur une durée de plusieurs dizaines de secondes, puis calculé la moyenne des valeurs mesurées pour chaque axe (X, Y, Z). Ces moyennes ont ensuite été utilisées comme biais statique à corriger.

Un graphique de l'évolution des mesures brutes au cours du temps met clairement en évidence cette dérive, notamment sur l'axe Z, où les valeurs mesurées restent significativement éloignées de zéro, avec un biais moyen autour de 0.6 rad/s, comme le montre la distribution des erreurs en page suivante.

Sur l'axe X, les valeurs présentent une forte dispersion autour de zéro, traduisant une instabilité importante, bien que la moyenne soit relativement proche de zéro. Cela suggère un bruit élevé mais un biais faible.

Sur l'axe Y, les mesures semblent plus stables, avec peu de valeurs extrêmes, et un biais très faible également.

Ces moyennes, représentées par des lignes pointillées rouges dans les histogrammes de distribution d'erreur, sont utilisées comme biais statiques à corriger dans les données brutes du gyroscope pour chaque axe.




Figure 1 : Acquisition Immobile du Gyroscope

2.5 Choix des paramètres d'acquisition

Nous avons adopté une démarche statistique pour le choix des paramètres d'acquisition. Vingt séries de mesures ont été réalisées en faisant varier au maximum les réglages des différents capteurs. Néanmoins, l'absence de référence externe (le smartphone) pour comparer nos résultats a posé la question suivante : comment choisir un bon paramétrage sans pouvoir évaluer précisément les erreurs systématiques ?

2.5.1 Test d'homogénéité des variances

Dans un premier temps, nous avons évalué l'impact des modifications de paramètres sur la dispersion des mesures à l'aide du test de Levene (<https://datatab.fr/tutorial/levene-test>). Ce test permet de vérifier l'hypothèse nulle selon laquelle plusieurs échantillons proviennent d'une population à variance identique. De plus, il accepte des échantillons de tailles différentes.

- H_0 : les groupes ont des variances égales.
- H_1 : les groupes ont des variances différentes.

Si la p-valeur obtenue est supérieure à 0,05, on ne peut pas rejeter H_0 : les variances sont jugées homogènes. Si elle est inférieure à 0,05, on conclut à une différence significative des variances.

Les hypothèses du test de Levene sont :

- observations indépendantes,
- variable mesurée à un niveau d'échelle métrique.

Nous avons implémenté ce test en Python, puis comparé nos résultats à ceux fournis par la fonction `levene` de la bibliothèque `SciPy` (cf. annexe).

2.5.2 Sélection empirique du meilleur paramétrage

Une fois l'impact des réglages mis en évidence, nous avons adopté une approche empirique : parmi les vingt acquisitions, nous avons sélectionné celle présentant l'écart-type le plus faible pour chaque capteur, indiquant la meilleure stabilité des mesures.

Cette méthode, bien que simple, permet de retenir un paramétrage optimisé en termes de précision, tout en restant compatible avec les contraintes énergétiques et informatiques évoquées précédemment.

2.6 Filtrage des signaux bruts

Le filtrage des données brutes consiste à effectuer un prétraitement afin d'améliorer la qualité des signaux issus des capteurs. L'objectif principal est de garantir la cohérence des acquisitions et de supprimer les valeurs aberrantes (outliers) susceptibles de fausser les analyses ou traitements ultérieurs.

2.6.1 Synchronisation des signaux

Avant tout traitement, nous avons procédé à la synchronisation temporelle des différentes acquisitions issues des capteurs (gyroscope, accéléromètre, magnétomètre, etc.). Cela permet de garantir que les mesures analysées correspondent aux mêmes instants physiques, ce qui est essentiel pour toute fusion ou comparaison de données multisources. La synchronisation a été réalisée en alignant les horodatages fournis par chaque capteur.

2.6.2 Détection des valeurs aberrantes

Une fois les données synchronisées, nous avons utilisé des représentations graphiques de type **boxplot** (ou boîtes à moustaches) pour visualiser la distribution des données de chaque capteur. Ces graphiques permettent d'identifier facilement les éventuelles valeurs aberrantes, c'est-à-dire les points très éloignés de la médiane ou dépassant l'intervalle interquartile étendu (défini en cours par $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$).

Ces valeurs peuvent provenir de bruits ponctuels, de pertes de signal ou d'erreurs transitoires dans la transmission. Elles ont été exclues des jeux de données à l'aide d'un filtre conditionnel simple basé sur ces bornes statistiques.

2.6.3 Lissage et filtrage complémentaire

En complément, un filtrage numérique a pu être appliqué sur certaines séries temporelles à fort bruit, notamment via un filtre passe-bas de type moyenne glissante (moving average) ou un filtre de Savitzky-Golay, selon le type de signal et le niveau de bruit observé. Cela permet de réduire les fluctuations rapides non représentatives sans altérer les tendances générales du mouvement.

2.6.4 Résultat du prétraitement

Après filtrage, les signaux présentent une meilleure continuité et une diminution significative du bruit. Les valeurs extrêmes ont été supprimées, rendant les signaux plus exploitables pour les étapes suivantes telles que la calibration dynamique ou la fusion multi-capteurs.

Chapitre 3

Présentation du système d'acquisition complet

3.1 Montage électrique

Le montage électrique mis en place repose sur l'intégration d'une Raspberry Pi et de capteurs connectés, associés à plusieurs équipements liés à la collecte des données. Les principaux composants connectés au système sont :

- un module GPS,
- un accéléromètre,
- un écran LCD
- Lidar

L'assemblage nécessite une attention particulière au niveau des branchements afin d'éviter toute perte de potentiel ou de court-circuit. Un schéma de câblage est également présenté ci-dessous :




Figure 2 : Schéma de câblage du montage

3.2 Description du produit (fonctionnalités, mode d'utilisation)

L'application développée atteint pleinement l'objectif initial du projet : proposer un système permettant de suivre son trajet sur une carte de manière interactive, à la manière de Strava.

Elle intègre une fonction de télémétrie pour comparer différents parcours (temps moyen, distance, vitesse, etc.) et permet un suivi précis grâce à l'intégration en temps réel d'un filtre de Kalman, combinant les données GPS et IMU pour améliorer la précision du positionnement.

En complément de ces fonctionnalités, une option de course d'orientation a été ajoutée. Elle permet à l'utilisateur de suivre un itinéraire défini par des points de passage, avec un système de validation à chaque balise franchie, offrant ainsi un usage ludique et sportif du dispositif.

3.3 Synchronisation des capteurs

La synchronisation des capteurs a été assurée à l'aide de l'heure UTC comme référence temporelle commune. Chaque échantillon de données, qu'il provienne du GPS ou de l'IMU, est horodaté avec un *timestamp* précis. Cela permet d'aligner chronologiquement les mesures issues des différents capteurs.

Grâce à cette méthode, nous avons pu constituer un jeu de données unifié, combinant de manière cohérente les informations GPS et IMU pour un traitement fiable, notamment lors de l'application du filtre de Kalman.

3.4 Fusion de données détaillée

On a principalement utilisé le filtre de Kalman (Voir Modélisation et Estimation par Filtre de Kalman du Chapitre 4).

Chapitre 4

Analyse des performances du système d'acquisition

4.1 Méthodologie pour la détermination du paramétrage du système d'acquisition

Pour déterminer les meilleurs réglages de nos capteurs, nous avons réalisé plusieurs acquisitions du même trajet, en changeant les paramètres à chaque fois. Cela nous a permis de comparer les résultats et d'évaluer l'impact de chaque réglage sur la qualité des données. Les paramètres modifiés sont les suivants :

- **Accéléromètre**
 - Plages : $\pm 2g$, $\pm 4g$, $\pm 8g$, $\pm 16g$
 - Fréquences : 12.5 Hz, 208 Hz, 833 Hz, 1660 Hz, 3330 Hz
- **Gyroscope**
 - Plages : ± 250 dps, ± 500 dps, ± 1000 dps, ± 2000 dps
 - Fréquences : 12.5 Hz, 208 Hz, 833 Hz, 1660 Hz, 3330 Hz
- **Magnétomètre**
 - Plages : ± 4 gauss, ± 8 gauss, ± 12 gauss, ± 16 gauss
 - Fréquences : 0.625 Hz, 5 Hz, 20 Hz, 150 Hz, 560 Hz

Toutes les acquisitions ont été faites sur le même parcours, mais à des jours différents. Les conditions météorologiques n'étaient donc pas les mêmes à chaque fois. Il est donc important de prendre ceci en compte, car cela peut influencer les mesures en introduisant une source de bruit supplémentaire.

Avant de commencer une acquisition, nous avons toujours laissé la carte d'acquisition immobile pendant quelques secondes pour que les capteurs puissent se stabiliser. Cependant, cela a été fait à proximité d'un bâtiment, ce qui n'est pas idéal, en particulier pour le magnétomètre qui peut être perturbé par les structures métalliques aux alentours. Un axe d'amélioration serait donc de débiter les acquisitions dans un environnement dégagé, loin des bâtiments, pour limiter ces perturbations.

4.2 Description et analyse du choix des méthodes statistiques avec les résultats obtenus

Nous avons implémenté manuellement le test de Levene afin de vérifier l'homogénéité des variances entre plusieurs acquisitions. Pour valider notre approche, nous avons comparé

les résultats obtenus à ceux fournis par la fonction `levane` de la bibliothèque `scipy`. Voici les différentes étapes du processus.

1. Importation des acquisitions

Nous avons commencé par importer les différentes séries de mesures à comparer :

```
Entrée [22]: import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
```

```
Entrée [23]: acquisition1 = pd.read_csv('results/mouvement_exterieur_4/mouvement_exterieur_4_imu.csv')
acquisition2 = pd.read_csv('results/mouvement_exterieur_4/mouvement_exterieur_4_imu.csv')
acquisition3 = pd.read_csv('results/mouvement_exterieur_4/mouvement_exterieur_4_imu.csv')
acquisition4 = pd.read_csv('results/mouvement_exterieur_4/mouvement_exterieur_4_imu.csv')
acquisition5 = pd.read_csv('results/mouvement_exterieur_5/mouvement_exterieur_5_imu.csv')
acquisition6 = pd.read_csv('results/mouvement_exterieur_6/mouvement_exterieur_6_imu.csv')
acquisition7 = pd.read_csv('results/mouvement_exterieur_7/mouvement_exterieur_7_imu.csv')
acquisition8 = pd.read_csv('results/mouvement_exterieur_8/mouvement_exterieur_8_imu.csv')
acquisition9 = pd.read_csv('results/mouvement_exterieur_9/mouvement_exterieur_9_imu.csv')
acquisition10 = pd.read_csv('results/mouvement_exterieur_10/mouvement_exterieur_10_imu.csv')
acquisition11 = pd.read_csv('results/mouvement_exterieur_11/mouvement_exterieur_11_imu.csv')
acquisition12 = pd.read_csv('results/mouvement_exterieur_12/mouvement_exterieur_12_imu.csv')
acquisition13 = pd.read_csv('results/mouvement_exterieur_13/mouvement_exterieur_13_imu.csv')
acquisition14 = pd.read_csv('results/mouvement_exterieur_14/mouvement_exterieur_14_imu.csv')

acquisitions = [
    acquisition1,
    acquisition2,
    acquisition3,
    acquisition4,
    acquisition5,
    acquisition6,
    acquisition7,
    acquisition8,
    acquisition9,
    acquisition10,
    acquisition11,
    acquisition12,
    acquisition13,
    acquisition14
]
```

```
Entrée [24]: acquisition1
```

Out[24]:

	Timestamp	Accel X	Accel Y	Accel Z	Gyro X	Gyro Y	Gyro Z	Magneto X	Magneto Y	Magneto Z
0	1.745335e+09	0.994483	0.065697	0.110044	-0.23625	0.34125	0.41125	-0.318328	0.126179	-0.176557
1	1.745335e+09	1.003694	0.076860	0.106323	-0.50750	0.28000	0.35000	-0.318328	0.126179	-0.176557
2	1.745335e+09	0.998021	0.064843	0.110593	-0.04375	0.29750	0.68250	-0.318036	0.126717	-0.180941
3	1.745335e+09	0.998387	0.062098	0.108702	1.56625	0.74375	0.93625	-0.318036	0.126717	-0.180941
4	1.745335e+09	0.995154	0.065514	0.105286	0.39375	-0.01750	0.88375	-0.319497	0.129933	-0.176703
...
50340	1.745336e+09	0.847351	0.038491	0.315370	34.92125	10.08875	-0.34125	-0.332797	0.092078	-0.199211
50341	1.745336e+09	0.871385	0.040565	0.267363	34.53625	11.08625	-1.61875	-0.329290	0.090909	-0.195703
50342	1.745336e+09	0.875411	0.053863	0.252052	34.09875	11.64625	-1.31250	-0.329290	0.090909	-0.195703
50343	1.745336e+09	0.870348	0.042456	0.256871	33.39000	13.07250	-0.14875	-0.327682	0.090909	-0.200526
50344	1.745336e+09	0.844240	0.036478	0.258823	33.39000	12.37250	-0.45500	-0.327682	0.090909	-0.200526

50345 rows x 10 columns

Test de Levene

<https://datatab.fr/tutorial/levane-test>

H0: Les groupes ont des variances égales
H1: Les groupes ont des variances différentes

2. Implémentation manuelle du test

Nous avons ensuite codé le test de Levene étape par étape, en calculant les écarts aux médianes puis les sommes de carrés nécessaires à l'évaluation statistique :

```
Entrée [25]: import numpy as np
from scipy.stats import f

#La normalisation des données peut se faire avec la moyenne ou bien la mediane,
#on aura décidé d'utiliser la mediane car c'est celle utilisé par scipy
def normalisation_moyenne(serie):
    moyenne = np.mean(serie)
    return [abs(x - moyenne) for x in serie]

def normalisation_median(serie):
    med = np.median(serie)
    return [abs(x - med) for x in serie]

def levene_a_la_main(acquisitions, type_acquisition):
    # Normaliser chaque groupe
    donnees_norm = []
    moyennes = []
    effectifs = []

    for acquisition in acquisitions:
        donnees_norm.append(normalisation_median(acquisition[type_acquisition]))
        moyennes.append(np.mean(normalisation_median(acquisition[type_acquisition])))
        effectifs.append(len(acquisition[type_acquisition]))

    # Moyenne globale de toutes les données normalisées regroupé
    toutes_donnees = [val for groupe in donnees_norm for val in groupe]
    moyenne_globale = np.mean(toutes_donnees)

    # SSB: Somme des carrés entre groupes
    SSB = 0
    for idx in range(len(acquisitions)):
        n_j = effectifs[idx]
        SSB += n_j * (moyennes[idx] - moyenne_globale) ** 2

    # SSW: Somme des carrés intra-groupes
    SSW = 0
    for idx in range(len(acquisitions)):
        values = donnees_norm[idx]
        for val in values:
            SSW += (val - moyennes[idx]) ** 2

    # Degrés de liberté
    k = len(acquisitions)
    N = sum(effectifs)
    dl1 = k - 1
    dl2 = N - k

    # Moyennes des carrés
    MSB = SSB / dl1
    MSW = SSW / dl2

    # Statistique F
    F_stat = MSB / MSW

    # Calcul de la p-value
    p_value = 1 - f.cdf(F_stat, dl1, dl2)

    return F_stat, p_value
```

```
Entrée [26]: stat, p_value = levene_a_la_main(acquisitions, "Accel X")
print(f"Statistique de test (fait main) : {stat:.4f}")
print(f"P-value : {p_value:.4f}")
```

```
Statistique de test (fait main) : 1324.5121
P-value : 0.0000
```

3. Validation avec scipy

Pour s'assurer de la validité de notre implémentation, nous avons comparé nos résultats à ceux de `scipy.stats.levene`. Une fois cette étape confirmée, nous avons utilisé les résultats pour sélectionner les meilleurs réglages :

```
Entrée [27]: #Verification
from scipy.stats import levene

stat2, p_value2 = levene(
    acquisitions[0]["Accel X"],
    acquisitions[1]["Accel X"],
    acquisitions[2]["Accel X"],
    acquisitions[3]["Accel X"],
    acquisitions[4]["Accel X"],
    acquisitions[5]["Accel X"],
    acquisitions[6]["Accel X"],
    acquisitions[7]["Accel X"],
    acquisitions[8]["Accel X"],
    acquisitions[9]["Accel X"],
    acquisitions[10]["Accel X"],
    acquisitions[11]["Accel X"],
    acquisitions[12]["Accel X"],
    acquisitions[13]["Accel X"]
)

print(f"Statistique (Scipy) : {stat2}")
print(f"P-value : {p_value2}")

Statistique (Scipy) : 1324.512896482796
P-value : 0.0
```

On retrouve le même résultat que Scipy !

Quel paramétrage ?

Comme on sait qu'il y a bien une différence parmi les acquisitions due au paramétrage.

```
Entrée [29]: colonnes = acquisitions[0].columns[1:]

for col in colonnes:
    stds = []
    for acq in acquisitions:
        series = acq[col]
        stds.append(np.std(series))

    idx_sorted = np.argsort(stds)

    print(f"Colonne {col} :")
    for rang, idx in enumerate(idx_sorted[1:], start=1):
        print(f"  Rang: {rang}. Acquisition {idx+1}, écart-type = {stds[idx]:.5f}")
    print(" ")

Colonne Accel X :
  Rang: 1. Acquisition 11, écart-type = 0.28029

Colonne Accel Y :
  Rang: 1. Acquisition 13, écart-type = 0.86956

Colonne Accel Z :
  Rang: 1. Acquisition 13, écart-type = 0.89181

Colonne Gyro X :
  Rang: 1. Acquisition 1, écart-type = 17.86821

Colonne Gyro Y :
  Rang: 1. Acquisition 6, écart-type = 11.86876

Colonne Gyro Z :
  Rang: 1. Acquisition 10, écart-type = 18.57794

Colonne Magneto X :
  Rang: 1. Acquisition 8, écart-type = 0.82638

Colonne Magneto Y :
  Rang: 1. Acquisition 12, écart-type = 0.84495

Colonne Magneto Z :
  Rang: 1. Acquisition 12, écart-type = 0.83663
```

À l'issue de cette analyse, nous avons retenu les acquisitions suivantes :

- Acquisition 13 pour l'accéléromètre,

- Acquisition 6 pour le gyroscope,
- Acquisition 12 pour le magnétomètre.

4.3 Analyse des résultats de tracking obtenus

4.3.1 Mouvement extérieur 1

Comparaison des trajets




Figure 3 : Comparaison trajet mouvement extérieur 1 (Gps vs Téléphone)

Dans cet exemple, on a fait deux tours à l'extérieur et on remarque qu'en prenant les données du téléphone comme repère. Le GPS qu'on utilise n'est pas trop mauvais. En effet, quand on fait la moyenne des deux trajectoires on retrouve une trajectoire qui ressemble au chemin pris lors de l'acquisition.

Comparaison latitude et longitude

On remarque que les mesures de latitude et de longitude effectuées à l'aide de notre GPS correspondent plutôt bien aux mesures réalisées au téléphone sur l'application GPS Logger.




Figure 4 : Comparaison latitude (Gps vs Téléphone)




Figure 5 : Comparaison longitude (Gps vs Téléphone) mouvement extérieur1

On constate cependant qu'en général les mesures prises par l'application mobile présentent des valeurs maximales (respectivement minimales) légèrement supérieures (respectivement inférieures).

Boite à moustache vitesse / accélération




Figure 6 : Boite à moustache

On observe une vitesse de marche moyenne de 1 mètre par seconde qui correspond à une vitesse moyenne de 4 kilomètre par heure environ sachant que la seconde boite à moustache présente une moyenne d'accélération nulle ce qui signifie que l'ensemble des acquisitions ont été effectuées dans les mêmes conditions exactement.

Evolution de l'erreur mouvement extérieur1




Figure 7 : Evolution de l'erreur en cours du temps

Ce graphe illustre l'évolution de l'erreur de position entre les mesures GPS et la position estimée par le téléphone durant un mouvement extérieur. On observe que l'erreur initiale est relativement élevée, atteignant environ 20 mètres, avant de diminuer de manière significative. Par la suite, l'erreur varie de façon irrégulière mais reste généralement comprise entre 2 et 15 mètres. Ces fluctuations peuvent être dues à plusieurs facteurs, tels que des interférences satellites, des obstacles environnementaux (bâtiments, arbres), ou encore des limitations du capteur du téléphone.

Globalement, on remarque une tendance à la stabilisation partielle de l'erreur après les premières observations, ce qui pourrait indiquer un temps d'adaptation ou de calibration du système GPS du téléphone. Ainsi, il faut attendre quelques secondes pour stabiliser avant de commencer nos prochaines acquisitions.

Valeurs aberrantes




Figure 8 : Valeurs aberrantes

La figure 8 présente deux graphiques illustrant la détection de **valeurs aberrantes** dans les séries temporelles de **vitesse** (graphique intitulé « Vitesse avec valeurs aberrantes ») et d'**accélération** (graphique intitulé « Accélération avec valeurs aberrantes ») mesurées lors de notre acquisition.

Le graphique « Vitesse avec valeurs aberrantes » montre l'évolution de la vitesse au cours du temps. La courbe bleue représente les vitesses considérées comme normales, tandis que les points rouges indiquent les *valeurs aberrantes* détectées. Ces dernières apparaissent de manière sporadique, souvent aux extrémités de la plage des données. Cela peut refléter des erreurs de capteurs ou des bruits de mesure. La majorité des valeurs se concentrent autour de 1 m/s, ce qui est cohérent avec une vitesse de marche humaine (cf Figure 6).

Le graphique « Accélération avec valeurs aberrantes » montre quant à lui l'évolution de l'accélération. La courbe verte indique les valeurs normales, tandis que les points rouges représentent les accélérations considérées comme aberrantes. On y observe une plus grande densité d'anomalies, ce qui est attendu puisque l'accélération, étant une dérivée seconde, est plus sensible au bruit. Les valeurs normales d'accélération sont généralement proches de zéro, tandis que les pics extrêmes sont identifiés comme des anomalies.

Ainsi, cette figure met en évidence l'importance de la détection de valeurs aberrantes pour améliorer la qualité et la fiabilité des mesures avant tout traitement ou analyse avancée.

4.4 Analyse des résultats obtenus en cas de défaillance cap- teur

4.4.1 Acquisition immobile extérieur 1

Comparaison trajet Gps vs Téléphone




Figure 9 : Comparaison trajet immobile extérieur 1 (Gps vs Téléphone)

On remarque que même à l'extérieur, les acquisitions du gps et du téléphone ne sont pas assez précises. Le trajet nous indique qu'on était en mouvement même si on était immobile.




Figure 10 : Comparaison latitude (Gps vs Téléphone)




Figure 11 : Comparaison longitude (Gps vs Téléphone)

Comparaison latitude et longitude

Boîte à moustache vitesse / accélération

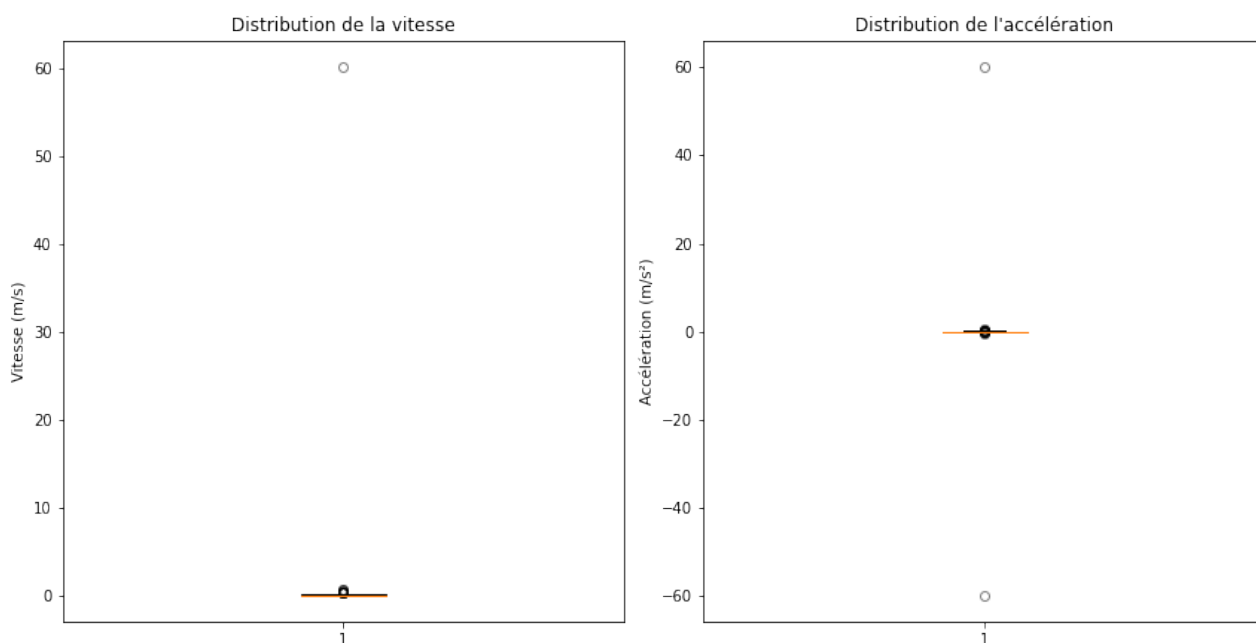


Figure 12 : Boîte à moustache

Evolution de l'erreur




Figure 13 : Evolution de l'erreur en cours du temps

Valeurs aberrantes




Figure 14 : Valeurs aberrantes

4.4.2 Acquisition immobile exterieur 2




Figure 15 : Comparaison trajet immobile exterieur 2 (Gps vs Téléphone)

Ici, on peut remarquer que les données fournies par le téléphone sont beaucoup plus précises que les données fournies par le GPS. En effet, on ne peut pas se fier aux données du GPS seulement. C'est l'une des raisons pour lesquelles on doit appliquer un filtre de Kalman et fusionner les capteurs.




Figure 16 : Comparaison latitude (Gps vs Téléphone) immobile extérieur 2




Figure 17 : Comparaison longitude (Gps vs Téléphone) immobile extérieur 2

Comparaison latitude et longitude

Boîte à moustache vitesse / accélération




Figure 18 : Boîte à moustache

Evolution de l'erreur




Figure 19 : Evolution de l'erreur en cours du temps

Valeurs aberrantes

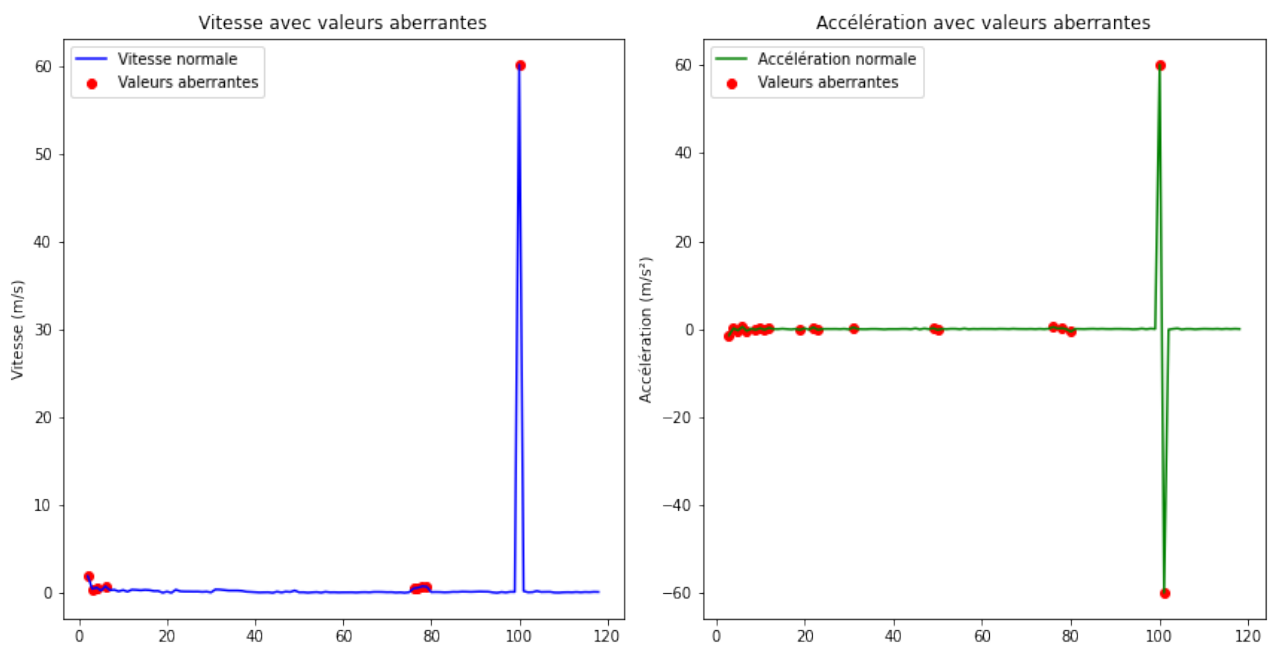


Figure 20 : Valeurs aberrantes

Conclusion

Les graphes ci-dessus montrent clairement que les données du GPS, prises seules, sont peu exploitables en raison du grand nombre de valeurs aberrantes, notamment lorsque le système est immobile. Cette instabilité s'explique par la faible précision instantanée du GPS grand public, soumise à de nombreux facteurs comme expliqué dans la section 2.3. Pour améliorer la qualité des mesures, il est essentiel d'attendre un certain seuil de temps — quelques secondes — après la mise en route afin de permettre aux capteurs de se stabiliser et de se calibrer correctement.

4.5 Filtrage des signaux bruts

Modélisation et Estimation par Filtre de Kalman

Données disponibles

Dans le cadre de ce projet, les données accessibles sont les suivantes :

- **Position GPS :**
 - θ : longitude (coordonnée est-ouest)
 - λ : latitude (coordonnée nord-sud)
- **Données de l'IMU (Inertial Measurement Unit) :**
 - **Accéléromètre :** Mesures d'accélération linéaire
 - a_x : accélération selon l'axe x
 - a_y : accélération selon l'axe y
 - a_z : accélération selon l'axe z
 - **Gyroscope :** Mesures de vitesse angulaire
 - $\dot{\omega}_x$: vitesse angulaire autour de l'axe x (roulis)
 - $\dot{\omega}_y$: vitesse angulaire autour de l'axe y (tangage)
 - $\dot{\omega}_z$: vitesse angulaire autour de l'axe z (lacet)
 - **Magnétomètre :** Mesures du champ magnétique terrestre
 - m_x : composante selon l'axe x
 - m_y : composante selon l'axe y
 - m_z : composante selon l'axe z

Remarques

- Les données GPS (θ, λ) donnent la position absolue, mais avec une précision limitée (erreur de quelques mètres).
- Les données de l'IMU fournissent des mesures inertielles précises à court terme, mais sujettes à une dérive temporelle (erreur qui s'accumule). De plus, l'accélération s'exprime dans le repère de l'IMU lui-même et non dans un repère terrestre.
- Le magnétomètre permet de s'orienter par rapport au nord magnétique, mais peut être perturbé par des interférences locales.

Premier modèle basique

En raison de la nature instable de certains de nos composants, nous serions tentés de créer des modèles de filtre de Kalman compliqués afin de pouvoir corriger les différentes erreurs qui s'accumulent. Mais pour débiter, nous souhaitons faire un modèle simple, linéaire, qui ne nécessite pas l'utilisation d'un filtre de Kalman étendu.

Rappel filtre de Kalman

En statistique et en théorie du contrôle, le filtre de Kalman est un estimateur récursif à réponse impulsionnelle infinie permettant d'estimer les états d'un système dynamique à partir de mesures bruitées ou incomplètes [?].

Le filtre de Kalman en contexte discret est un estimateur récursif : l'état courant est estimé à partir de l'estimation de l'état précédent et des mesures actuelles. Le filtre de Kalman suppose que le processus discret réel \mathbf{x}_k (où k dénote l'indice de temps), suit la loi d'évolution linéaire suivante :

$$\mathbf{x}_k = \mathbf{F}_k \mathbf{x}_{k-1} + \mathbf{G}_k \mathbf{u}_k + \mathbf{w}_k$$

où :

- \mathbf{F}_k : matrice de transition entre l'état $k - 1$ et l'état k
 - \mathbf{u}_k : commande d'entrée
 - \mathbf{G}_k : matrice de contrôle reliant \mathbf{u}_k et \mathbf{x}_k
 - \mathbf{w}_k : bruit d'évolution, gaussien centré de covariance \mathbf{Q}_k
- L'observation \mathbf{z}_k à l'instant k est donnée par :

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{v}_k$$

avec :

- \mathbf{H}_k : matrice d'observation à l'instant k
- \mathbf{v}_k : bruit de mesure

Prétraitement des données

Maintenant que nous savons quels éléments nous devons définir ainsi que les données que nous avons à notre disposition, nous pouvons modéliser le système. Cependant, un problème apparaît : nos acquisitions sont en coordonnées sphériques. Cela complique les traitements, qui risquent de ne pas être linéaires. Il est donc préférable de les transformer en coordonnées cartésiennes pour pouvoir appliquer un modèle linéaire, notamment pour l'intégration dans un filtre de Kalman classique.

Pour convertir les coordonnées sphériques en coordonnées cartésiennes, on utilise :

$$x = R_t \cos(\lambda) \cos(\theta)$$

$$y = R_t \cos(\lambda) \sin(\theta)$$

$$z = R_t \sin(\lambda)$$

avec :

- R_t : rayon terrestre
- λ : latitude en radians
- θ : longitude en radians

Comme dit plus haut, les accélérations sont exprimées dans le repère local de l'accéléromètre. Pour que notre filtre fonctionne correctement, il faut les exprimer dans le repère terrestre. On applique donc une matrice de rotation à nos vecteurs d'accélération.

Les angles d'orientation sont obtenus par intégration des vitesses angulaires :

$$\omega_{x,k+1} = \omega_{x,k} + \dot{\omega}_{x,k} \Delta t \quad (1)$$

$$\omega_{y,k+1} = \omega_{y,k} + \dot{\omega}_{y,k} \Delta t \quad (2)$$

$$\omega_{z,k+1} = \omega_{z,k} + \dot{\omega}_{z,k} \Delta t \quad (3)$$

Conditions initiales :

$\omega_{x,0}, \quad \omega_{y,0}, \quad \omega_{z,0}$ calculés à $t = 0$ avec les données du magnétomètre

On en déduit la matrice de rotation R_k à appliquer à nos vecteurs d'accélération à l'instant k :

$$R_k = R_{\omega_{x,k}} R_{\omega_{y,k}} R_{\omega_{z,k}}$$

Ainsi, on obtient l'accélération dans le repère terrestre :

$$\tilde{\mathbf{a}} = \begin{pmatrix} \tilde{a}_x \\ \tilde{a}_y \\ \tilde{a}_z \end{pmatrix} = R_k \begin{pmatrix} a_x \\ a_y \\ a_z \end{pmatrix}$$

Modélisation du problème

Toutes nos données sont désormais transformées pour être utilisables.

On définit le vecteur d'état \mathbf{x}_k :

$$\mathbf{x}_k = \begin{pmatrix} x \\ y \\ z \\ v_x \\ v_y \\ v_z \end{pmatrix}$$

À partir des équations classiques du mouvement, on a :

$$\begin{cases} x_{k+1} = x_k + v_{x,k} dt + \frac{1}{2} \tilde{a}_{x,k} dt^2 \\ y_{k+1} = y_k + v_{y,k} dt + \frac{1}{2} \tilde{a}_{y,k} dt^2 \\ z_{k+1} = z_k + v_{z,k} dt + \frac{1}{2} \tilde{a}_{z,k} dt^2 \\ v_{x,k+1} = v_{x,k} + \tilde{a}_{x,k} dt \\ v_{y,k+1} = v_{y,k} + \tilde{a}_{y,k} dt \\ v_{z,k+1} = v_{z,k} + \tilde{a}_{z,k} dt \end{cases}$$

Ce système est mis sous forme matricielle :

$$\mathbf{x}_{k+1} = \mathbf{F}_k \mathbf{x}_k + \mathbf{G}_k \mathbf{u}_k + \mathbf{w}_k$$

avec :

$$\mathbf{F}_k = \begin{pmatrix} 1 & 0 & 0 & dt & 0 & 0 \\ 0 & 1 & 0 & 0 & dt & 0 \\ 0 & 0 & 1 & 0 & 0 & dt \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \quad \text{et} \quad \mathbf{G}_k = \begin{pmatrix} \frac{1}{2} dt^2 & 0 & 0 \\ 0 & \frac{1}{2} dt^2 & 0 \\ 0 & 0 & \frac{1}{2} dt^2 \\ dt & 0 & 0 \\ 0 & dt & 0 \\ 0 & 0 & dt \end{pmatrix}$$

et $\mathbf{u}_k = \tilde{\mathbf{a}}_k$

Enfin, comme on souhaite observer uniquement la position, la matrice d'observation \mathbf{H}_k est :

$$\mathbf{H}_k = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \end{pmatrix}$$

Analyse des résultats

Après implémentation et exécution du filtre de Kalman sur les données disponibles, nous pouvons analyser les résultats obtenus afin d'évaluer la performance et la pertinence de notre modèle basique.

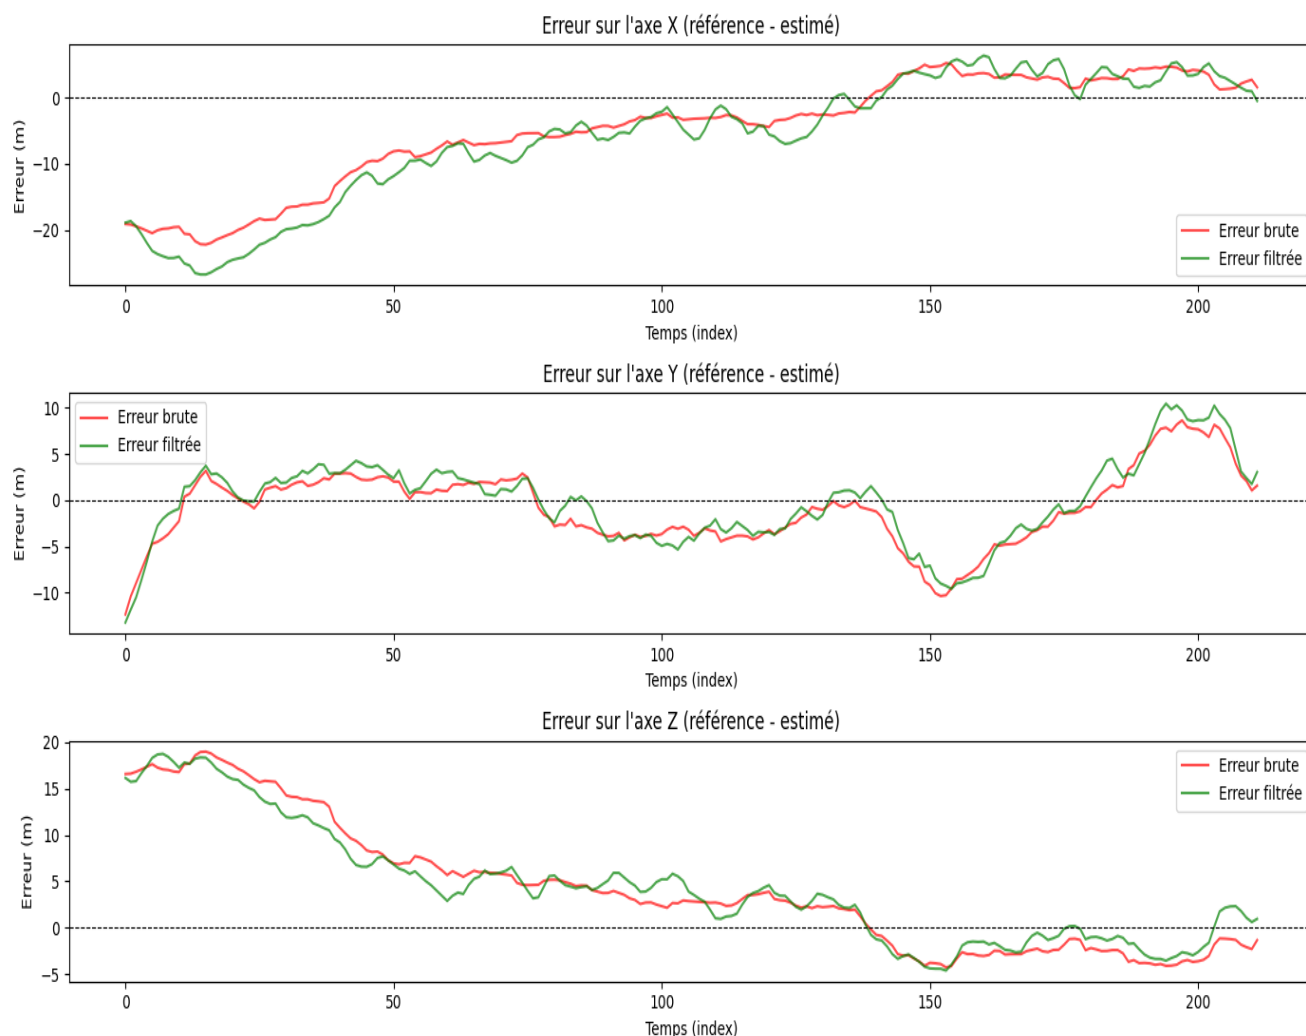


FIGURE 1 – Comparaison erreur trajet filtré / non filtré (acquisition 20)

Analyse des erreurs et amélioration par filtrage (acquisition 20)

Analyse des erreurs – Axe X

RMSE avant filtrage : 9.402 m
RMSE après filtrage : 11.171 m \Rightarrow Pas amélioré
Erreur moyenne (kf) : -6.046 m
Écart-type erreur (kf) : 9.394 m
Corrélation ref vs x_k^f : 0.916

Analyse des erreurs – Axe Y

RMSE avant filtrage : 4.194 m
RMSE après filtrage : 4.485 m \Rightarrow Pas amélioré
Erreur moyenne (kf) : -0.199 m
Écart-type erreur (kf) : 4.480 m
Corrélation ref vs y_{kf} : 0.987

Analyse des erreurs – Axe Z

RMSE avant filtrage : 8.065 m
RMSE après filtrage : 7.570 m \Rightarrow Amélioré
Erreur moyenne (kf) : 4.345 m
Écart-type erreur (kf) : 6.200 m
Corrélation ref vs z_{kf} : 0.947




FIGURE 2 – Comparaison erreur trajet filtré / non filtré (acquisition 19)

Analyse des erreurs et amélioration par filtrage (acquisition 19)

Analyse des erreurs – Axe X

RMSE avant filtrage : 8.332 m_ RMSE après filtrage : 9.783 m \Rightarrow Pas amélioré
Erreur moyenne (kf) : -5.598 m
Écart-type erreur (kf) : 8.023 m
Corrélation ref vs x_{kf} : 0.945

Analyse des erreurs – Axe Y

RMSE avant filtrage : 8.728 m
RMSE après filtrage : 7.788 m \Rightarrow Amélioré
Erreur moyenne (kf) : -1.159 m
Écart-type erreur (kf) : 7.701 m
Corrélation ref vs y_{kf} : 0.964

Analyse des erreurs – Axe Z

RMSE avant filtrage : 7.145 m
RMSE après filtrage : 6.575 m \Rightarrow Amélioré
Erreur moyenne (kf) : 2.176 m
Écart-type erreur (kf) : 6.204 m
Corrélation ref vs z_{kf} : 0.946

Conclusion globale

En raison d'une mauvaise méthodologie d'acquisition des données nous ne disposons que de ces 2 échantillons pour pouvoir vérifier l'efficacité du test de Kalman. Nous avons fait la quasi totalité de nos acquisitions sans mesurer en même temps un trajet de référence, ce qui rend la quasi totalité de nos acquisitions inutilisables pour des traitements relatifs au filtre de Kalman.

On voit bien sur les résultats de nos acquisition que le filtre n'est pas parfait. Le trajet 20 n'est pas amélioré après filtrage, le trajet 19 si.

Le filtre de Kalman linéaire implémenté n'a pas permis d'améliorer significativement la qualité de l'estimation. Cela suggère que le modèle de mouvement utilisé est trop simplifié ou que l'hypothèse de linéarité ne convient pas aux données réelles. Une extension vers un filtre de Kalman étendu (EKF) ou une meilleure prise en compte des non-linéarités (coordonnées sphériques, rotation, etc.) pourrait être nécessaire pour améliorer les performances globales.

Limites du modèle basique

Malgré ces améliorations, certaines limitations inhérentes au modèle simplifié apparaissent :

- **Approximation linéaire** : Le modèle linéaire ne prend pas en compte les non-linéarités dues à la dynamique réelle du déplacement ou des capteurs, ce qui peut dégrader les performances en cas de mouvements complexes.
- **Modélisation des bruits** : Les matrices de covariance \mathbf{Q}_k (processus) et \mathbf{R}_k (mesure) doivent être choisies avec soin. Un mauvais calibrage peut engendrer une mauvaise estimation, oscillante ou trop lente à réagir.
- **Dérive gyroscopique et erreurs d'orientation** : L'intégration des vitesses angulaires pour calculer la matrice de rotation R_k accumule les erreurs au fil du temps, impactant la qualité de la transformation des accélérations et donc l'estimation des vitesses et positions.
- **Perturbations du magnétomètre** : Les interférences magnétiques locales peuvent fausser l'orientation initiale et rendre instable la transformation vers le repère terrestre.

Perspectives d'amélioration

Pour pallier ces limites, plusieurs axes d'amélioration peuvent être envisagés :

- Utilisation d'un **filtre de Kalman étendu (EKF)** ou **filtre de Kalman unscented (UKF)** afin de mieux gérer les non-linéarités dans la dynamique et l'observation.
- Intégration d'un modèle plus complet de la dynamique du système, par exemple en incluant les angles d'orientation comme variables d'état, pour mieux estimer la matrice de rotation.
- Calibration plus fine des matrices de bruit et étude des modèles statistiques des erreurs spécifiques aux capteurs.
- Fusion avec d'autres capteurs, comme un baromètre pour la hauteur, ou des systèmes de correction GPS différentiel pour réduire les erreurs absolues.

Conclusion

Ce premier modèle linéaire simple de filtre de Kalman permet d'établir une base pour la fusion des données GPS et IMU. Il montre une amélioration dans certains de la qualité d'estimation de la position par rapport aux mesures brutes. Cependant, les limites relevées invitent à développer un modèle plus complet et adapté aux spécificités des capteurs et de la dynamique étudiée pour une application finale plus précise et fiable.

Conclusion

Ce projet nous a permis de concevoir et de réaliser un système complet d'estimation de trajectoire basé sur la fusion de données capteurs, avec pour objectif de proposer une alternative simplifiée à des applications comme Strava.

Nous avons étudié, calibré et synchronisé différents capteurs (GPS, accéléromètre, gyroscope, magnétomètre), tout en développant une application capable d'en exploiter les mesures en temps réel. L'intégration d'un filtre de Kalman a constitué une étape centrale, permettant de combiner efficacement les données GPS et IMU afin d'améliorer la précision de localisation.

Nous avons également enrichi notre système d'une fonctionnalité de course d'orientation, rendant l'usage plus ludique et interactif. Sur le plan méthodologique, nous avons mis en œuvre des outils statistiques rigoureux pour optimiser les paramètres d'acquisition, détecter les valeurs aberrantes et évaluer les performances du système.

Malgré quelques limitations dans la validation expérimentale, dues à un manque de données de référence sur certaines acquisitions, les résultats obtenus sont prometteurs. Ce travail ouvre la voie à des perspectives d'amélioration, notamment en explorant des variantes non linéaires du filtre de Kalman, en affinant les modèles dynamiques ou en intégrant d'autres sources de données.

Enfin, ce projet nous a permis de mobiliser un large éventail de compétences — théoriques, pratiques et collaboratives — tout en nous confrontant à une problématique proche d'un contexte réel d'ingénierie. Il constitue une expérience formatrice riche, tant sur le plan technique que dans la gestion de projet en équipe.

Bibliographie

- [1] Stéphane Calderon, Floris Chabert. *Filtrage de Kalman appliqué à une centrale inertielle multi-capteurs*, École Nationale Supérieure des Télécommunications, Paris. Disponible à : <https://igns.wdfiles.com/local--files/filtre-de-kalman/Kalman.pdf>, (Consulté le 01/04/2025).
- [2] *Matrice jacobienne*, Wikipédia, l'encyclopédie libre. Disponible à : https://fr.wikipedia.org/wiki/Matrice_jacobienne, (Consulté le 01/04/2025).
- [3] *Filtre de Kalman*, Wikipédia, l'encyclopédie libre. Disponible à : https://fr.wikipedia.org/wiki/Filtre_de_Kalman, (Consulté le 01/04/2025).